Lab #01 — Mini Data Warehouse ShopX
Extração e Transformação de Dados

Francisco Sousa, João Nuno 53642, 51557 IACD

Março 2025

1 Contexto e motivação

A empresa fictícia *ShopX* possui dados dispersos em diferentes fontes (clientes, produtos e vendas), dificultando análises históricas consistentes. O objetivo deste trabalho é implementar um mini-*Data Warehouse* para suportar consultas analíticas (OLAP), agregando medidas de vendas ao longo do tempo e permitindo análises por produto e por localização do cliente, conforme requisitos do enunciado.

Os requisitos principais incluem: (i) analisar volume/valor de vendas por categoria e por mês; (ii) acompanhar valor total vendido ao longo do tempo; (iii) analisar distribuição geográfica (por cidade/região); (iv) acompanhar evolução de novos clientes ao longo dos períodos. [**?**]

2 Modelo dimensional proposto

Foi adotado um **Esquema Estrela (Star Schema)**, com uma tabela de factos central (`FactVendas`) e três dimensões (`DimTempo`, `DimProduto`, `DimCliente`).

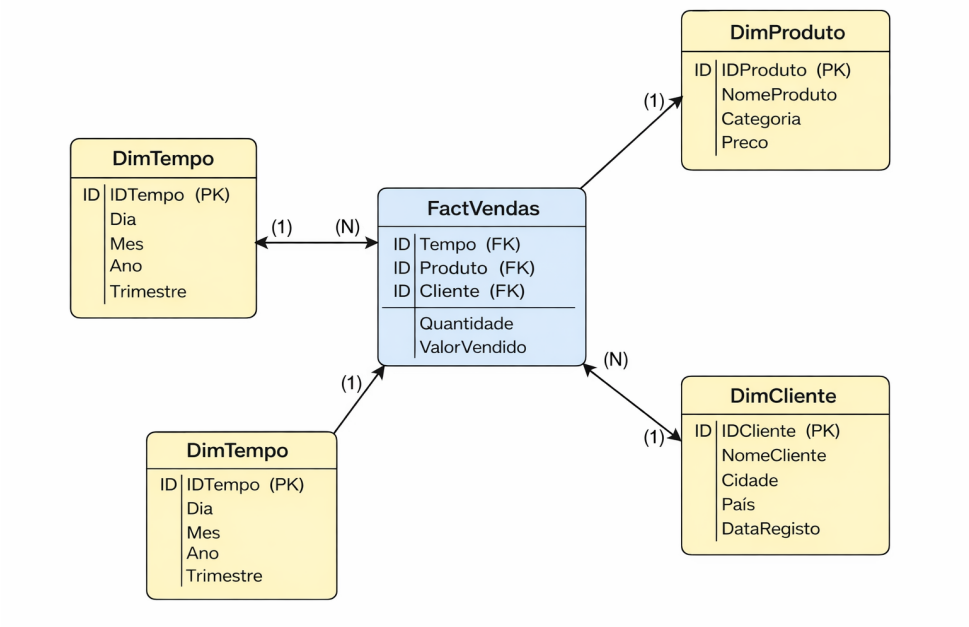

Figura 1: Representação do Modelo Dimensional em Esquema Estrela

Tabela de factos

`FactVendas`: contém as medidas e chaves para dimensões.

- **Chaves estrangeiras**: `IDTempo`, `IDProduto`, `IDCliente`
- **Medidas**: `Quantidade` (unidades vendidas) e `ValorVendido` (receita)

Dimensões

- `DimTempo`: atributos de calendário (Dia, Mês, Ano, Trimestre), permitindo agregações temporais.
- `DimProduto`: nome/descrição, categoria e preço (suporte a análises por portefólio).
- `DimCliente`: nome, cidade, país e data de registo (suporte a análises geográficas e novos clientes).

3 Processo de carga (ETL simplificado)

O processo ETL seguiu as etapas:

1. **Extração**: leitura das fontes (clientes, produtos e vendas).
2. **Transformação**: normalização de datas, conversão de tipos numéricos, remoção de duplicados e validação de chaves (garantir correspondência entre SKU/ID de produto e ID de cliente).
3. **Carga**: inserção nas dimensões (`DimCliente`, `DimProduto`, `DimTempo`) e, em seguida, carga da `FactVendas` respeitando integridade referencial.

4 Consultas OLAP e interpretação de resultados

Nesta secção apresentam-se exemplos de consultas analíticas e a respetiva interpretação.

4.1 Vendas por mês e categoria

Consulta (exemplo do enunciado):

```
SELECT dT.Ano, dT.Mes, dProd.Categoria,
       SUM(fV.Quantidade) AS TotalQtd,
       SUM(fV.ValorVendido) AS TotalValor
FROM FactVendas fV
JOIN DimTempo dT   ON fV.IDTempo   = dT.IDTempo
JOIN DimProduto dProd ON fV.IDProduto = dProd.IDProduto
GROUP BY dT.Ano, dT.Mes, dProd.Categoria
ORDER BY dT.Ano, dT.Mes;
```

Resultados (excerto observado):
Interpretação:

- A categoria **Eletrónica** domina a receita no período observado, com valores elevados em fevereiro (999.0), abril (999.0) e especialmente maio (2022.9), sugerindo vendas de maior ticket médio nessa categoria.
- **Vestuário** apresenta mais unidades em vários meses (ex.: janeiro e fevereiro com 3 unidades), mas com receita inferior, indicando produtos de menor preço unitário.
- **Acessórios** tem baixa expressão em valor total, apesar de ocorrer em meses diferentes, sugerindo contribuição marginal no mix.

Tabela 1: Vendas por mês e categoria (excerto)

Ano	Mês	Categoria	TotalQtd	TotalValor
2022	1	Calçado	1	59.9
2022	1	Eletrónica	1	299.0
2022	1	Vestuário	3	79.7
2022	2	Acessórios	1	29.9
2022	2	Eletrónica	1	999.0
2022	2	Vestuário	3	59.7
2022	3	Calçado	1	59.9
2022	3	Eletrónica	1	299.0
2022	3	Vestuário	2	39.8
2022	4	Acessórios	2	59.8
2022	4	Eletrónica	1	999.0
2022	4	Vestuário	3	169.7
2022	5	Acessórios	1	49.9
2022	5	Eletrónica	3	2022.9
2022	6	Eletrónica	1	59.0
2022	6	Vestuário	1	19.9

4.2 Top 5 produtos por receita total

```
SELECT TOP 5 dProd.NomeProduto,
       SUM(fV.ValorVendido) AS ReceitaTotal
FROM FactVendas fV
JOIN DimProduto dProd ON fV.IDProduto = dProd.IDProduto
GROUP BY dProd.NomeProduto
ORDER BY ReceitaTotal DESC;
```

Tabela 2: Top 5 produtos por receita total

Produto	ReceitaTotal
Portátil Pro 15	6993
Smartphone X1	1495
TV 42 Polegadas	898
Cadeira de Escritório	796
Sofá 3 Lugares	499

Interpretação:

- O **Portátil Pro 15** é o principal gerador de receita (6993), muito acima do 2º lugar, indicando forte dependência de um produto premium.
- Os restantes produtos têm receitas bem inferiores, sugerindo uma distribuição assimétrica (efeito *long tail*) no portefólio.

4.3 Distribuição geográfica: volume de vendas por cidade

```
SELECT dCli.Cidade,
       SUM(fV.ValorVendido) AS VolumeVendas
FROM FactVendas fV
```

```
JOIN DimCliente dCli ON fV.IDCliente = dCli.IDCliente
GROUP BY dCli.Cidade
ORDER BY VolumeVendas DESC;
```

Tabela 3: Volume de vendas por cidade (top e cauda)

Cidade	VolumeVendas
Lisboa	3647.4
Faro	2386.7
Porto	1996.3
Braga	1330.1
Coimbra	1058.8
Setúbal	169.6
Viseu	89.8

Interpretação:

- **Lisboa** lidera o volume de vendas, seguida de **Faro** e **Porto**, sugerindo maior concentração de receita em grandes centros urbanos/turísticos.
- Cidades como **Viseu** e **Setúbal** apresentam valores baixos, podendo justificar campanhas locais, otimização de stock/região ou investigação de cobertura comercial.

4.4 Evolução de novos clientes

```
SELECT YEAR(DataRegisto) AS Ano,
       MONTH(DataRegisto) AS Mes,
       COUNT(IDCliente) AS NovosClientes
FROM DimCliente
GROUP BY YEAR(DataRegisto), MONTH(DataRegisto)
ORDER BY Ano, Mes;
```

Tabela 4: Novos clientes por mês (excerto observado)

Ano	Mês	NovosClientes
2021	1	1
2021	3	1
2021	4	1
2021	5	1
2021	7	2
2021	8	1
2021	9	1
2021	10	1
2021	11	1
2021	12	2
2022	1	1
2022	2	2
2022	3	2
2022	4	1
2022	5	1
2022	6	1
2022	7	1

Interpretação (mensal e trimestral):

- Em 2021 observa-se maior captação em **julho** e **dezembro** (2 clientes/mês), sugerindo sazonalidade (período de verão e Natal).
- Agregando por trimestre (com base no excerto): **2021Q1** = **2**, **2021Q2** = **2**, **2021Q3** = **4**, **2021Q4** = **4**. Há reforço claro em Q3 e Q4.
- Em 2022, o primeiro trimestre é mais forte (**2022Q1** = **5**) do que o segundo (**2022Q2** = **3**), indicando boa dinâmica de aquisição no arranque do ano.

5 Conclusão

O mini-DW implementado consolida dados operacionais e permite análises históricas por tempo, produto e localização. Os resultados demonstram:

- forte peso da categoria **Eletrónica** na receita e um produto *top* com grande impacto (**Portátil Pro 15**);
- concentração geográfica das vendas em **Lisboa**/**Faro**/**Porto**;
- evidência de sazonalidade na captação de novos clientes (picos em Q3/Q4 de 2021 e Q1 de 2022).

Estes padrões suportam decisões de gestão como foco de campanhas por região, análise de dependência de produtos premium e planeamento sazonal de marketing.